

Complete Evaluation Metrics Guide — Template v4.0

S.M Azman Sikder Durjay | কোন competition-এ কোন metric | monitor_metric কী দেবে | code কোথায় বসবে

① কোন Competition-এ কোন Metric — আগে এটা ঠিক করো

Metric নাম	কোন Data Type	Competition Example	monitor_metric	monitor_mode	সংক্ষিপ্ত ব্যাখ্যা
Accuracy	Balanced	Dog Breed, Cassava, Cats vs Dogs	val_accuracy	max	সব class-এর ছবি প্রায় সমান। সরল metric — সঠিক predict/মোট predict।
AUC-ROC	Imbalanced	Skin Cancer (ISIC), Fraud Detection, Medical	val_auc	max	99% normal, 1% disease — accuracy দিলে সবসময় 99% পাবে। AUC দিলে আসল performance বোঝা যায়।
F1 Score (Macro)	Imbalanced	Hackathon, Plant Disease, NLP classification	val_f1	max	Precision ও Recall-এর harmonic mean। সব class সমান গুরুত্ব পায়। TF 2.16+ only।
Log Loss	Probability sub	Dog Breed, State Farm (probability submission)	val_loss	min	Probability output কতটা confident। Lower = better। Kaggle evaluation-এ সবচেয়ে common।
Top-5 Accuracy	Many Classes	Dog Breed (120+), iNaturalist (555+)	val_top5_acc	max	Top-5 prediction-এ সঠিক class থাকলেই pass। 120 class-এ useful। num_classes > 5 হলে auto-add হয়।
QW Kappa	Ordinal / Ranked	APTOS (0-4 grade), Prostate Cancer (0-5)	val_loss (Keras-এ নেই, sklearn only)	min	Grade-এ কাছাকাছি ভুলকে কম penalty দেয়। 0 vs 4 ভুল worse than 0 vs 1 ভুল।
mAP	Multilabel	Human Protein Atlas, Chest X-Ray (14 disease)	val_map	max	Mean Average Precision — multilabel-এর main metric। প্রতিটি class আলাদাভাবে evaluate হয়।
Binary Accuracy	Binary / Multilabel	Cats vs Dogs, Toxic Comment	val_accuracy	max	2-class বা multilabel-এ threshold=0.5 দিয়ে evaluate। sigmoid output-এর জন্য।

② Template-এ কোথায় কীভাবে Update করবে

কী Update করবে	CFG Block-এ কোড	কখন পরিবর্তন করবে
Monitor Metric বদলানো BLOCK B → monitor_metric	monitor_metric = 'val_accuracy' monitor_metric = 'val_auc' monitor_metric = 'val_loss' monitor_metric = 'val_f1'	Kaggle-এর Evaluation tab দেখো — সেখানে যা লেখা (Accuracy/AUC/LogLoss) সেটার সাথে মেলাও। Default val_accuracy বেশিরভাগ competition-এ কাজ করে।
Monitor Mode বদলানো BLOCK B → monitor_mode	monitor_mode = 'max' — accuracy, AUC, F1 monitor_mode = 'min' — loss, log_loss	Loss monitor করলে 'min' দাও। বাকি সব metric-এ 'max' দাও।
Augmentation Domain Section 3 train_datagen	General: fill_mode='nearest' Medical/Skin: fill_mode='reflect' Medical: rotation_range=90 Medical: vertical_flip=True	Skin/Cell/Medical competition-এ reflect ও vertical_flip=True দাও। General object-এ nearest রাখো।
Metric Code বদলানো Section 7 get_metrics()	Template-এ সব metric আছে ✅ F1Score: TF 2.16+ auto-check TopK: num_classes>5 auto-add	সাধারণত কিছু করতে হবে না। শুধু monitor_metric বদলালেই ModelCheckpoint ও EarlyStopping auto-update হবে।

③ Section 7 — get_metrics() Complete Code Reference

Section 7 — get_metrics() এ যা আছে ও কীভাবে customize করবে

def get_metrics():
 is_ml = (CFG.task_type == 'multilabel')

 m = [
 'accuracy',
 tf.keras.metrics.AUC(multi_label=is_ml, name='auc'),
 tf.keras.metrics.AUC(curve='PR', multi_label=is_ml, name='map'),
 tf.keras.metrics.Precision(name='pre'),
 tf.keras.metrics.Recall(name='rec'),
]

 # ← সবসময় থাকে
 # ← AUC (multiclass OvR)
 # ← mAP (PR curve)
 # ← Precision
 # ← Recall

```
try: # F1Score: TF 2.16+ only — পুরোনো TF-এ auto-skip
    m.append(tf.keras.metrics.F1Score(average='macro', name='f1'))
except AttributeError: pass

if CFG.num_classes > 5: # Top-5: 120+ class competition-এ auto-add
    m.append(tf.keras.metrics.TopKCategoryicalAccuracy(k=5, name='top5_acc'))

return m

# — sklearn metrics (Section 8 _evaluate_model এ) —
from sklearn.metrics import roc_auc_score, f1_score, cohen_kappa_score, average_precision_score

# Macro AUC (multiclass-এর সঠিক AUC — OvR strategy)
roc_auc_score(y_true_oh, y_pred_prob, multi_class='ovr', average='macro')

# Macro F1
f1_score(y_true, y_pred, average='macro')

# Quadratic Weighted Kappa (ordinal: APTOS, Prostate grading)
cohen_kappa_score(y_true, y_pred, weights='quadratic')

# Mean Average Precision
average_precision_score(y_true_oh, y_pred_prob, average='macro')
```

④ Monitor Metric → ModelCheckpoint → EarlyStopping — কীভাবে কাজ করে

Template-এ একটাই জায়গায় বদলালেই হয়: `CFG.monitor_metric` — ModelCheckpoint ও EarlyStopping দুটোই auto-update হবে।

Kaggle metric	CFG.monitor_metric	CFG.monitor_mode	কখন use করবে + কী save হবে
Accuracy	<code>val_accuracy</code>	<code>max</code>	Dog Breed, Cassava, Cats vs Dogs। সর্বোচ্চ <code>val_accuracy</code> -তে best model save।
AUC / ROC	<code>val_auc</code>	<code>max</code>	Skin Cancer, ISIC, Medical। সর্বোচ্চ <code>val_auc</code> -তে save — imbalanced data-তে সঠিক।
Log Loss	<code>val_loss</code>	<code>min</code>	Probability submission competition। সর্বনিম্ন <code>val_loss</code> -এ save।
F1 Score	<code>val_f1</code>	<code>max</code>	F1-based hackathon। TF 2.16+ only — পুরোনো TF-এ <code>val_accuracy</code> দাও।
mAP	<code>val_map</code>	<code>max</code>	Multilabel competition (Protein Atlas)। PR-AUC as mAP proxy।
QW Kappa	<code>val_loss</code> (Keras-এ QWK নেই)	<code>min</code>	APTOS, Prostate। Keras-এ QWK metric নেই — <code>val_loss</code> দিয়ে proxy করো। Actual QWK শুধু <code>_evaluate_model()</code> -এ দেখা যাবে।

⑤ Quick Decision Guide — Competition শুরু হলে ৫ মিনিটে Metric ঠিক করে

Kaggle-এর Evaluation tab-এ কী লেখা?	monitor_metric	monitor_mode
"Submissions are scored on accuracy "	<code>val_accuracy</code>	<code>max</code>
"Submissions are scored using log loss " / "multi-class logarithmic loss"	<code>val_loss</code>	<code>min</code>
"Submissions are scored on AUC " / "area under the ROC curve"	<code>val_auc</code>	<code>max</code>
" Mean F1 score " / "macro F1"	<code>val_f1</code> (TF 2.16+) অথবা <code>val_accuracy</code>	<code>max</code>
" Mean Average Precision " / "mAP"	<code>val_map</code>	<code>max</code>
" Quadratic Weighted Kappa "	<code>val_loss</code>	<code>min</code>
কিছু বোঝা যাচ্ছে না / নিশ্চিত না	<code>val_accuracy</code>	<code>max</code> (safe default)

Critical Warning: `monitor_metric`-এ যে name দেবে সেটা `get_metrics()` এ থাকতে হবে। `val_f1` দিলে F1Score metric অবশ্যই list-এ থাকতে হবে — না থাকলে EarlyStopping ও ModelCheckpoint crash করবে। Template-এ সব আছে ✅ — শুধু TF version check করো।

সবচেয়ে **safe approach**: প্রথমে `val_accuracy + max` দিয়ে শুরু করো। Leaderboard-এ score খারাপ আসলে Kaggle-এর Evaluation tab দেখে `monitor_metric` বদলাও।